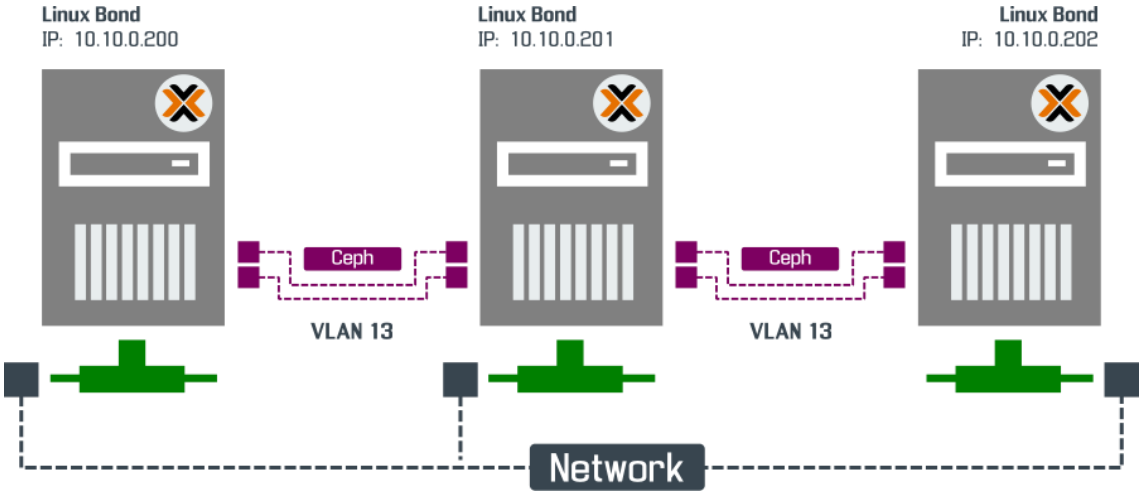
Escuela de Ciencia de la Computación
Examen Parcial
CC531 A Análisis en Macrodatos 2026-2

Parte 1 [6 pts]:
Resolver en el laboratorio de clase de forma presencial 6 preguntas de teoría de forma individual, en hoja y con lapicero, abarca todos los temas hasta el parcial.

Parte 2 [14 pts]:
Se pide configurar y programar un Clúster de Hadoop e instalar Hadoop multimodo 1 maestro y 2 o más esclavos, en máquinas virtuales mínima de Ubuntu siguiendo el tutorial y demostración presentado en clase, Desarrollar un informe, Una presentación y Exponer sobre una base de datos para su Análisis según las siguientes restricciones:



Implementar:

- Implementar un Clúster de Hadoop e instalar Hadoop multimodo **1 maestro y 2 o más esclavos**, en máquinas virtuales de Ubuntu o Windows usando virtual box u otro virtualizador a su criterio. **Es estrictamente necesario que la implementación sea mediante máquinas virtuales.**

- Elaborar un informe en el cual:

    - **Adicional a las secciones de siempre, crear una sección inicial de implementación donde se describirá a grandes rasgos los pasos seguidos con capturas de la configuración.**
    - **Adjuntando las capturas de pantalla de cada paso de configuración y la pantalla final donde aparecen los nodos conectados.**

- **Implementar o usar su VM de un nodo para que comparen rendimientos en los trabajos realizados.**

- Buscar un Dataset de la Plataforma Nacional de Datos Abiertos (PNDA) que no haya sido expuesto en las PC por ningún grupo (base de datos) y que sea de las **categorías TRANSPORTE Y MOVILIDAD O VIVIENDA URBANISMO O TERRITORIO, el cual debe tener los campos de latitud y longitud**. **Revisar en el cuadro de temas los ya utilizados por los otros grupos, no se admitirá datasets repetidos ni con muestras de datos en diferentes periodos.**

- Tanto en el informe como en la presentación:

    - Referenciar la base de datos usada.
    - Referencias investigaciones anteriores realizadas a la base datos.
    - Indicar la fuente de dataset y la fecha de publicación, se tomará en cuenta las bases de datos más recientes.

- Referenciar artículos que usaron su dataset si lo hubiera hecho.

- Implementar Consultas de complejidad en Hadoop
    - Hacer 2 consultas con decimales que implique al menos un Mapreduce triple. Cada consulta por separado debe tener el Mapreduce triple como se vio en clase.
    - Implementar 1 consulta que implemente un algoritmo de agrupamiento (a excepción de K-means) basado íntegramente en Hadoop Mapreduce sobre las coordenadas geográficas.
    - Implementar 2 consultas con campos decimales o cadenas que implementen 2 modelos de multilayer perceptrón, 1 de clasificación y 1 de regresión, usando el concepto clásico de gradiente descendiente en Hadoop Mapreduce.
- Correr su código en el clúster implementado y en la versión de un solo nodo (El que implementaron para la PC1).
- Implementar una tabla de comparación que mida: Los tiempos de ejecución, el speedup, uso promedio de CPU y memoria en paralelo y en un solo nodo. La tabla y explicación de la razón de las salidas debe estar en el informe y en la presentación.
- Adicionar en el informe la imagen del monitor de recursos de la ejecución en paralelo (ejemplo htop) de memoria, de cada procesador, y tiempos de ejecución de cada caso de los nodos en la red, para observar el paralelismo de los procesos.
- Para el caso de las preguntas de Machine learning elaborar una tabla donde se compare las métricas de perdida, accuracy y otras medidas propias que elijan para cada modelo en los casos paralelos y 1 solo nodo, para compararlos.
- De igual forma hacer una tabla comparativa de métricas de evaluación del agrupamiento como Silhouette Score o Davies-Bouldin Index aplicados en cluster y 1 solo nodo.
- En el informe y presentación para mantener la organización por cada consulta se debe mencionar:
    - Especificar el tipo de pregunta o grupo de pregunta.
    - Mencionar la consulta en el Dataset a la cual responde. Ejem: “Cual es el promedio de marcas usadas…”
    - Explicar la solución y resultados.
- Agregar al informe y presentación los inputs y outputs que pudiera tener sus consultas.
- Con los resultados obtenidos de las consultas implementar gráficos usando Power BI y adjuntarlos a su informe y presentación. Al menos un gráfico que use las coordenadas geográficas y los resultados del agrupamiento.
- Durante la exposición se debe mostrar la ejecución del clúster implementado distribuido y el de un solo nodo.

Entregables:

- Utilizar las plantillas adjuntas en la tarea.
- Códigos con la extensión JAVA y los JAR (obligatorio)
- Informe y presentación (Obligatorio)
- El dataset utilizado.
- Imágenes y fuente del powerBI. (Obligatorio)
- Cada miembro del grupo deberá entrega lo antes mencionado en un zip por el aula virtual.

Observaciones importantes:

- Está prohibido que dos o más grupos utilicen el mismo dataset incluso con rango de fechas o sub-partes diferentes, de presentarse el caso no se evaluará a ningún de los grupos involucrados.
- El tiempo límite de exposición es de 10 minutos, de pasarse ese tiempo o hacer bulla o

distracción en el aula se aplicarán descuento de puntos.

- Todos los entregables deben presentarse como máximo hasta la fecha establecida en el aula virtual. No se darán plazo adicional de entrega.
- De no presentarse todo entregable calificado como obligatorio, dado que son componentes básicos para demostrar el trabajo realizado, no se evaluará dicho trabajo o se colocará un puntaje en base a lo que pueda ser verificado.
- La cantidad de participantes por grupo será de 1 a 3 personas como máximo.
- Es obligatoria que la implementación del clúster sea usando máquinas virtuales y que los algoritmos de agrupamiento y ML sean implementados íntegramente usando MapReduce no se admitirán otras librerías de ayuda relacionadas.
- Todos los miembros del grupo deben estar presentes durante la exposición, si un participante no viene a exponer no se le considerará la nota.