

OLAP

My deals table

Date	Deal	Bonus, \$
1 May	Lease	2.000
2 May	Bought	2.000
2 May	Bought	3.000
3 May	Sold	8.000
1 May	Sold	5.000
1 May	Sold	10.000

My bonus report

	Sold	Bought	Lease
1 May	15.000 \$	—	2.000 \$
2 May	—	5.000 \$	—
3 May	8.000 \$	—	—


Arquitectura de un DWH

- OLTP
- Load Manager
- DW Manager
- Query Manager


ARQUITECTURA DE UN DATA WAREHOUSING

The title is centered on a dark green background. Below the title, there are several horizontal bars: a thick green bar, followed by a thin white bar, and then two more thin green bars. These bars extend across the width of the slide, with some segments being slightly offset to create a layered effect.

Arquitectura de un DWH




Arquitectura




- Los datos son extraídos desde aplicaciones, bases de datos, archivos, etc.
- Los datos son integrados, transformados y limpiados, para ser cargados en el DW
- La información del DW se estructura en cubos multidimensionales, los cuales preparan esta información para responder a consultas dinámicas con una buena performance.
- Los usuarios acceden a los cubos multidimensionales del DW utilizando herramientas de consulta, exploración, análisis, reportes, etc.


OLTP



- OLTP (On Line Transaction Processing), información transaccional generada por la empresa en su operación.
- Diferentes formatos, procedencia, función, configuración.
 - Archivos de textos.
 - Hipertextos.
 - Hojas de cálculos.
 - Informes semanales, mensuales, anuales, etc.
 - Bases de datos transaccionales.




ETL




ETL (Extracción, Transformación y Carga).

- **Extracción.** Desde los OLTP
- **Transformación.** Manipulación, integración, solución de inconsistencias.
- **Carga.** Carga en el DWH



ETL. Extracción

- Extrae los datos relevantes desde diversas fuentes OLTP.




- Procesamiento sin paralizar el OLTP, ni el DWH
- Gestiona los metadatos del proceso ETL.
- Facilita la integración de fuentes internas y externas.
- Tablas auxiliares y temporales para cálculos intermedios.
- El DWH se puebla desde estas tablas.




ETL . Transformación

- Convierte datos inconsistentes en datos compatibles y congruentes, para ser cargados en el DW.
 - Codificación.
 - Medida de atributos.
 - Convenciones de nombramiento.
 - Fuentes múltiples.
- Limpieza de Datos (Data Cleaning).
 - Datos no existentes (missing values).
 - Datos extremos (outliers)




ETL . Transformación


Codificación.




Medida de atributos.



Convenciones de nombramiento.




Fuentes múltiples.



ETL. Transformación


Datos no existentes

- El dato no existe por que:
 - No fue registrado en el momento
 - En la integración de BD una de ellas no tiene esa columna




Datos extremos

- Se presenta por que:
 - Caso excepcional
 - Error de digitación.




ETL. Carga


- Carga el DWH con:
 - Datos transformados que residen en tablas temporales.
 - Datos de OLTP que tienen correspondencia directa.



El proceso ETL



- Extracción. Se extraen datos relevantes desde los OLTP y se depositan en **tablas temporales**.
- Transformación. Se integran y transforman los datos en las **tablas temporales** para evitar inconsistencias.
- Carga. Se carga desde las **tablas temporales** al DWH.




Si existe correspondencia directa entre los datos del OLTP y del DWH, se procede a la carga.

Tareas del ETL



- Initial Load (Carga Inicial)
 - Primera carga.
 - Movimiento de gran cantidad de datos.
 - Fuerte consumo de tiempo.
- Incremental Load (Carga Incremental o actualización)
 - Mantenimiento o refresco periódico (frecuencia de actualización)
 - Movimiento de pocos datos (nuevos o modificados).
 - Problema control de cambios (desde la fecha anterior)
 - Identificar las instancias de los OLTP involucradas.
 - Utilizar disparadores (triggers) en los OLTP.
 - Recurrir a marcas de tiempo (Time Stamp).
 - Comparar los datos existentes en los dos ambientes (OLTP y DW).
- Full Load (Carga total)
 - Si el control de cambios es complejo, cargar desde cero.

Administración del DWH






- Transforma los datos fuentes en un modelo dimensional.
- Gestiona los datos mediante tablas de hechos y de dimensiones (repositorio de datos)
- Las tablas de hechos y dimensiones permiten crear cubos OLAP
- Permite ejecutar sentencias MDX (Multidimensional Expressions).
- Define las políticas de particionamiento de la tabla de hechos para mejorar la eficiencia de las consultas.
- Ejecuta copias de respaldo.

Base de Datos Multidimensionales

- Una BDMD se usa para crear aplicaciones OLAP.
- Cada tabla almacena registros de la forma:

$D_1, D_2, D_3, \dots M_1, M_2, M_3, \dots$

- Cada tabla se relaciona a un hipercubo (o un cubo OLAP)



Base de Datos Multidimensionales

- Cada tabla almacena registros de la forma:

$D_1, D_2, D_3, \dots M_1, M_2, M_3, \dots$


- D_i es una dimensión
 - Describe un aspecto del negocio.
 - Define la organización lógica de los datos.
 - Provee un medio para analizar datos del negocio.
 - Permite filtrar y manipular los datos almacenados
- M_i es una medida (hecho)
 - Siempre son numéricas
 - Cruzan todas las dimensiones en todos los niveles.
 - Son indicadores sumariados (sumas, promedios, mínimo, máximo, total, %)

Fact Table


Time
Product
Customer
Employee
Total
Quantity
Freight
Discount

Modelos Multidimensionales


- Esquema en Estrella (Star Scheme).
- Esquema Copo de Nieve (Snowflake Scheme).
- Esquema Constelación (Starflake Scheme).



Esquema Estrella



Esquema Copo de Nieve



Esquema Constelación




Tabla de dimensiones


- Definen la organización lógica de los datos.

GEOGRAFIA	PRODUCTOS	CLIENTES	FECHAS
 id_Geografía País Provincia Ciudad Barrio	 id_Producto Rubro Tipo NombreProducto	 id_Cliente NombreCliente	 id_Fecha Año Trimestre Mes Día

- Tiene una PK (única) y columnas de referencia:
 - Clave principal (PK) o identificador único.
 - Clave foráneas.
 - Datos de referencia primarios (identifican la dimensión)
 - Datos de referencia secundarios (complementan la descripción).
- No siempre la PK del OLTP, corresponde con la PK de la tabla de dimensión relacionada (¿por qué?)

Tablas de Hechos

- Las tablas de hechos contienen hechos.
- Los hechos o medidas son los valores de datos que se analizan (son numéricos).
- La tabla de hechos tiene una **clave primaria** compuesta por las claves primarias de las tablas de dimensiones relacionadas a este.
- *Los hechos son aquellos datos que residen en una tabla de hechos y que son utilizados para crear indicadores, a través de sumalizaciones preestablecidas al momento de crear un cubo multidimensional.*



Hechos o medidas


- Las medidas representan los valores que son analizados:
 - Cantidad de pacientes admitidos
 - Llamadas efectuadas.
 - $\text{ImporteTotal} = \text{precioProducto} * \text{cantidadVendida}$
 - $\text{Rentabilidad} = \text{utilidad} / \text{PN}$
 - $\text{CantidadVentas} = \text{cantidad}$
 - $\text{PromedioGeneral} = \text{AVG}(\text{notasFinales})$
- Valores numéricos porque estos valores son las bases de las cuales el usuario puede realizar cálculos.
- Si la medida es no numérica debemos codificarla a un valor numérico y cuando tengamos que exponerla decodificarla para mostrarla con el valor original.

Hechos o medidas


- Características de las medidas:
 - Deben ser numéricas.
 - Cruzan todas las dimensiones en todos los niveles.
- Las medidas pueden clasificarse en:
 - Naturales**
 - Estas formas de agregación pueden ser:
 - Suma: es la operación que suma los valores de las columnas
 - Cuenta: realiza un conteo de los valores
 - Mínima: devuelve un valor mínimo
 - Máxima: proporciona el mayor de los valores
 - Cuenta de Distintos: cuenta los valores diferentes
 - Calculadas**
 - Cálculos Matemáticos
 - Expresiones condicionales
 - Alertas

Cubos Multidimensionales o hipercubos


- Representa o convierte datos planos que se encuentran en filas y columnas, en una matriz de N dimensiones.
- Los **atributos** existen a lo largo de varios ejes o dimensiones y la intersección de ellas representa el valor que tomará el **indicador**.



La idea de multidimensionalidad



El Cubo



Indicadores, Atributos y Jerarquías

Los objetos a incluir en un cubo son:




- Los **indicadores**, son sumalizaciones (suma, conteo, promedio, etc), efectuadas sobre algún **hecho**. Dependen de los **atributos**/jerarquías que se utilicen para analizarlos.
- Los **atributos**, son criterios utilizados para analizar los **indicadores**. Se basan, en los datos de referencia de las tablas de **dimensiones**.

En un cubo, los **atributos** son los ejes del mismo.

Son campos o criterios de análisis, pertenecientes a tablas de **dimensiones**.


Indicadores, Atributos y Jerarquías

- Una **jerarquía** representa una relación lógica entre dos o más **atributos**; si poseen una relación “padre-hijo”.
- Tienen las siguientes características:
 - Existen varias en un mismo cubo.
 - Tienen dos o más niveles.
 - Relación “1-n” o “padre-hijo” entre atributos consecutivos de un nivel superior y uno inferior.
- Se pueden identificar cuando existen relaciones “1-n” o “padre-hijo” entre los propios atributos de un cubo.




Granularidad

- La **granularidad** es el nivel de detalle en que se almacena la información.
- Por ejemplo:
 - Datos de ventas o compras de una empresa, pueden registrarse día a día
 - Datos pertinentes a pagos de sueldos o cuotas de socios, podrán almacenarse a nivel de mes.
- A mayor nivel de detalle, mayor posibilidad analítica, ya que los mismos podrán ser resumidos o sumariados.
- Los datos con granularidad fina (nivel de detalle) podrán ser resumidos hasta obtener una granularidad media o gruesa. No sucede lo mismo en sentido contrario.





Consultas



- Ejecuta consultas relacionales, tales como Join y agregaciones, y de consultas propias del análisis de datos, como drill-up y drill-down.
- Una consulta consiste en obtener **indicadores** desde una tabla de hechos, restringidas por las propiedades o condiciones de los **atributos**.
- Las operaciones pueden ser:
 - Drill-down.
 - Drill-up.
 - Drill-across.
 - Roll-across.
 - Pivot.
 - Page.

Ejemplo

- Sea el siguiente esquema estrella



Drill-down


Datos
originales

TIEMPO - Año	PRODUCTOS - Producto	PRODUCTOS - Clase	MARCAS - Marca	VENTAS - Venta
2007	Producto1	A1	M1	22
2007	Producto1	B1	M1	18
2007	Producto1	A1	M2	33
2007	Producto1	B1	M2	19
2007	Producto1	A1	M3	15
2007	Producto1	B1	M3	10
2007	Producto2	A2	M1	21
2007	Producto2	B2	M1	18
2007	Producto2	A2	M2	30
2007	Producto2	B2	M2	35
2007	Producto2	A2	M3	26
2007	Producto2	B2	M3	22

Drill-down

TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Matricialmente



Drill-up


Datos
originales

TIEMPO - Año	PRODUCTOS - Producto	PRODUCTOS - Clase	MARCAS - Marca	VENTAS - Venta
2007	Producto1	A1	M1	22
2007	Producto1	B1	M1	18
2007	Producto1	A1	M2	33
2007	Producto1	B1	M2	19
2007	Producto1	A1	M3	15
2007	Producto1	B1	M3	10
2007	Producto2	A2	M1	21
2007	Producto2	B2	M1	18
2007	Producto2	A2	M2	30
2007	Producto2	B2	M2	35
2007	Producto2	A2	M3	26
2007	Producto2	B2	M3	22

Drill-up

TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Matricialmente



Drill-across

Datos
originales


TIEMPO - Año	PRODUCTOS - Producto	VENTAS - Venta
2007	Producto1	117
2007	Producto2	152

Se analiza a
mayor detalle
agregando un
criterio más

Drill-across

TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Matricialmente



Roll-across


Datos
originales

TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Roll-across

TIEMPO - Año	PRODUCTOS - Producto	VENTAS - Venta
2007	Producto1	117
2007	Producto2	152

Matricialmente



Pivot

Datos
originales


MARCAS - Marca	TIEMPO - Año	PRODUCTOS - Producto	VENTAS - Venta
M1	2007	Producto1	40
M1	2007	Producto2	39
M2	2007	Producto1	52
M2	2007	Producto2	65
M3	2007	Producto1	25
M3	2007	Producto2	48

Selecciona el
orden de
visualización
de atributos e
indicadores

Roll-across


TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Matricialmente



Page

- Presenta el cubo dividido en secciones, mediante valores de un atributo, como si se tratase de páginas de un libro:



Page

- Pivot permite realizar las siguientes acciones:
 1. Mover un atributo o indicador desde el encabezado de fila al encabezado de columna.
 2. Mover un atributo o indicador desde el encabezado de columna al encabezado de fila.
 3. Cambiar el orden de los atributos o indicadores del encabezado de columna.
 4. Cambiar el orden de los atributos o indicadores del encabezado de fila.
- Es muy útil cuando las consultas devuelven muchos registros y es necesario desplazarse por los datos para poder verlos en su totalidad.

Page

Datos
originales


TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Página 1

Producto1		
TIEMPO - Año	MARCAS - Marca	VENTAS - Venta
2007	M1	40
2007	M2	52
2007	M3	25

Matricialmente

PRODUCTOS - Producto



Page

Datos
originales

TIEMPO - Año	PRODUCTOS - Producto	MARCAS - Marca	VENTAS - Venta
2007	Producto1	M1	40
2007	Producto1	M2	52
2007	Producto1	M3	25
2007	Producto2	M1	39
2007	Producto2	M2	65
2007	Producto2	M3	48

Página 1

Producto2		
TIEMPO - Año	MARCAS - Marca	VENTAS - Venta
2007	M1	39
2007	M2	65
2007	M3	48

Matricialmente

PRODUCTOS - Producto	Producto1	40	52	25
	Producto2	39	65	48
		M1	M2	M3
		MARCAS - Marca		
		2007		
		TIEMPO - Año		

